



AutoAIM Studio

Manual de Usuario

Machine Learning Automatizado para Ciencia de Materiales

César Gabriel Vera de la Garza & Serguei Fomine

Versión 1.0.0 | 2026

Primer Lanzamiento Estable

Índice de Contenidos

Haz clic derecho en el índice y selecciona "Actualizar campo" para refrescar los números de página

Introducción	3
Primeros Pasos	4
Pestaña Data (Datos)	5
Pestaña Training (Entrenamiento)	7
Pestaña Neural Network (Red Neuronal)	9
Pestaña Optimization (Optimización)	11
Pestaña Results (Resultados)	13
Pestaña Ensemble (Conjunto)	14
Pestaña Explainability (Explicabilidad)	15
Pestaña Predict (Predicción)	17
Solución de Problemas	19
Referencia de Características	21
Apéndice: Algoritmos de Modelos	22
Tarjeta de Referencia Rápida	24
Cita y Licencia	25

Introducción

AutoAIM Studio es una plataforma integral de machine learning diseñada para aplicaciones de ciencia de materiales. Proporciona una interfaz gráfica intuitiva para preprocesamiento de datos, entrenamiento de modelos, optimización de hiperparámetros, construcción de redes neuronales, modelado de conjuntos (ensemble) e interpretación de modelos.

Características Principales

- Preprocesamiento Automático de Datos: Manejo de valores faltantes, codificación categórica y escalado de características.
- Ingeniería de Características de Composición: Genera 106 descriptores basados en composición a partir de fórmulas químicas.
- Múltiples Algoritmos de ML: Random Forest, Gradient Boosting, XGBoost, LightGBM, CatBoost, SVR, Ridge.
- Constructor de Redes Neuronales: Diseño de arquitectura visual con capas personalizables.
- Optimización de Hiperparámetros: Optimización Bayesiana con Optuna.
- Modelado de Conjuntos (Ensemble): Combina múltiples modelos para predicciones mejoradas.
- Interpretabilidad de Modelos: Valores SHAP, importancia por permutación, gráficos de dependencia parcial.
- Modo de predicción independiente: Despliega modelos entrenados para inferencia en nuevos datos.

Requisitos del Sistema

 **Nota:** Asegúrate de que tu sistema cumpla con estos requisitos para un rendimiento óptimo.

- Windows 10/11 (64-bit).
- 8GB RAM mínimo (16GB recomendado).
- GPU compatible con CUDA (opcional, para aceleración de redes neuronales).

Primeros Pasos

Iniciando la Aplicación

1. Haz doble clic en el archivo `AutoAIM Studio.exe`
2. La ventana principal se abrirá con múltiples pestañas en la parte superior
3. Comienza cargando tus datos en la pestaña Data (Datos)

Visión General del Flujo de Trabajo

El flujo de trabajo típico sigue estos pasos:

- Cargar Datos → Pestaña Data (Datos)
- Preprocesar → Pestaña Data (manejar valores faltantes, codificar categóricas)
- Generar Características → Pestaña Data (opcional, descriptores de composición)
- Entrenar Modelos → Pestaña Training (Entrenamiento) o Neural Network (Red Neuronal)
- Optimizar → Pestaña Optimization (Optimización) (opcional, para ajuste de hiperparámetros)
- Crear Conjuntos → Pestaña Ensemble (Conjunto) (opcional, combinar modelos)
- Analizar Resultados → Pestaña Results (Resultados)
- Interpretar Modelos → Pestaña Explainability (Explicabilidad)
- Hacer Predicciones → Pestaña Predict (Predicción)

 **Pro Tip:** Comienza con un conjunto de datos pequeño para familiarizarte con el flujo de trabajo antes de procesar grandes volúmenes de datos.

Pestaña Data (Datos)

La pestaña Data (Datos) es tu punto de partida para cargar y preparar tu conjunto de datos.

Cargando Datos

1. Haz clic en el botón **"Load Data" (Cargar Datos)**
2. Selecciona tu archivo de datos (formato CSV o Excel soportado)
3. La vista previa de los datos aparecerá en la tabla inferior

Formatos Soportados

- Archivos CSV (.csv)
- Archivos Excel (.xlsx, .xls)

Vista Previa de Datos

Después de cargar, verás:

- Shape (Forma): Número de filas y columnas.
- Columns (Columnas): Lista de todos los nombres de columnas.
- Data Types (Tipos de Datos): Detección automática de columnas numéricas y categóricas.
- Sample Data (Muestra de Datos): Primeras filas de tu conjunto de datos.

Selección de Columna Objetivo

1. Selecciona tu variable objetivo del menú desplegable **"Target Column" (Columna Objetivo)**
2. El sistema detectará automáticamente si es un problema de regresión o clasificación

Opciones de Preprocesamiento

Manejar Valores Faltantes

Casilla: **"Handle missing values" (Manejar valores faltantes)**. Cuando está habilitado, los valores numéricos faltantes se imputan con la mediana. Los valores categóricos faltantes se imputan con el valor más frecuente.

Codificar Variables Categóricas

Casilla: **"Encode categorical variables" (Codificar variables categóricas)**. Cuando está habilitado, las variables categóricas se codifican one-hot. Esto expande las columnas categóricas en múltiples columnas binarias.

Escalar Características

Casilla: "Scale features" (Escalar características). Cuando está habilitado, las características se estandarizan (media cero, varianza unitaria). Recomendado para algoritmos sensibles a escalas de características (SVR, Redes Neuronales).

Generar Características de Composición

Casilla: "Generate composition features (106 descriptors)" (Generar características de composición - 106 descriptores). **Requiere:** Una columna que contenga fórmulas químicas (ej., "Fe2O3", "SiO2"). Cuando está habilitado, el sistema extrae 106 descriptores basados en composición incluyendo:

- Estadísticas de número atómico (media, desv. est., mín, máx).
- Estadísticas de masa atómica.
- Estadísticas de electronegatividad.
- Estadísticas de radio covalente.
- Estadísticas de energía de ionización.
- Y muchas más propiedades de materiales.

 **Materials Science Context:** El generador de características de composición es una implementación personalizada diseñada para aplicaciones de ciencia de materiales. Analiza fórmulas químicas y calcula estadísticas agregadas basadas en propiedades elementales.

Preparando Datos

Después de configurar las opciones:

1. Haz clic en el botón "Prepare Data" (Preparar Datos)
2. El sistema dividirá los datos en conjuntos de entrenamiento/prueba (80/20 por defecto)
3. Se aplican todos los pasos de preprocesamiento seleccionados
4. Aparecerá un mensaje de confirmación cuando se complete

Pestaña Training (Entrenamiento)

La pestaña Training (Entrenamiento) te permite entrenar múltiples modelos de machine learning simultáneamente.

Selección de Modelos

Selecciona uno o más modelos de la lista:

Random Forest:Conjunto de árboles de decisión, bueno para predicción de propósito general

Gradient Boosting:Conjunto secuencial, a menudo logra alta precisión

XGBoost:Gradient boosting optimizado, estándar de la industria

LightGBM:Gradient boosting rápido con crecimiento hoja por hoja

CatBoost:Gradient boosting optimizado para características categóricas

SVR:Support Vector Regression, bueno para conjuntos de datos más pequeños

Ridge:Regresión lineal con regularización L2, línea base simple

Configuración de Entrenamiento

- Problem Type (Tipo de Problema): Detectado automáticamente (regresión/clasificación).
- Cross-Validation Folds (Pliegues de CV): Número de pliegues para evaluación (por defecto: 5).
- Random State (Estado Aleatorio): Semilla para reproducibilidad (por defecto: 42).

Proceso de Entrenamiento

1. Selecciona los modelos deseados (marca las casillas)
2. Haz clic en "Train Selected Models" (Entrenar Modelos Seleccionados)
3. El progreso se mostrará en la barra de estado
4. Los resultados aparecerán automáticamente en la pestaña Results (Resultados)

Entendiendo los Resultados

Después del entrenamiento, cada modelo muestra:

- RMSE: Root Mean Squared Error (menor es mejor).
- MAE: Mean Absolute Error (menor es mejor).
- R^2 : Coeficiente de determinación (mayor es mejor, máx 1.0).
- Training Time (Tiempo de Entrenamiento): Cuánto duró el entrenamiento.

⚡ **Pro Tip:** Para conjuntos de datos de ciencia de materiales, recomendamos comenzar con Random Forest y XGBoost, ya que a menudo proporcionan el mejor equilibrio entre precisión e interpretabilidad.

Pestaña Neural Network (Red Neuronal)

La pestaña Neural Network (Red Neuronal) proporciona una interfaz visual para diseñar y entrenar redes neuronales personalizadas.

Diseño de Arquitectura

Número de Capas Ocultas

Usa el cuadro de número para establecer 1-5 capas ocultas. Cada capa puede configurarse independientemente.

Configuración de Capas

Para cada capa oculta, puedes establecer:

- Units (Unidades): Número de neuronas (16-2048).
- Activation Function (Función de Activación): ReLU, Leaky ReLU, Tanh, Sigmoid, GELU, ELU.
- Dropout Rate (Tasa de Dropout): Regularización (0.0-0.5).
- Batch Normalization (Normalización por Lotes): Habilitar/deshabilitar.

Vista Previa de Arquitectura

Haz clic en "Update Architecture Preview" (Actualizar Vista Previa de Arquitectura) para ver:

- Dimensiones de la capa de entrada.
- Configuraciones de capas ocultas.
- Dimensiones de la capa de salida.
- Número total de parámetros.
- Parámetros entrenables.

Configuración de Entrenamiento

Parámetro	Descripción	Rango
Epochs (Épocas)	Número de iteraciones de entrenamiento	10-10,000
Batch Size (Tamaño de Lote)	Muestras por actualización de gradiente	8-512
Learning Rate (Tasa de Aprendizaje)	Tamaño de paso para optimización	0.00001-0.1
Optimizer (Optimizador)	Algoritmo de optimización	Adam, AdamW, SGD, RMSprop

Parámetro	Descripción	Rango
Weight Decay (L2)	Fuerza de regularización	0.0-0.1
Early Stopping Patience	Detener si no hay mejora	5-500 épocas

Proceso de Entrenamiento

1. Configura la arquitectura y parámetros de entrenamiento
2. Haz clic en "Train Neural Network" (Entrenar Red Neuronal)
3. Observa el progreso del entrenamiento:
 - La barra de progreso muestra la época actual
 - El registro muestra pérdida de entrenamiento/validación por época
4. El entrenamiento se detiene automáticamente cuando:
 - Se alcanzan las épocas máximas, 0.
 - Se activa early stopping (sin mejora).

Guardando Redes Neuronales

Después del entrenamiento:

1. Haz clic en "Save Model" (Guardar Modelo)
2. Elige el formato:
 - PyTorch Model (.pt): Formato simple.
 - Model Bundle: Incluye manifest.json, modelo y preprocesador (recomendado para pestaña Predict).

 **Importante:** Guarda siempre como Model Bundle si planeas usar el modelo en la pestaña Predict. El bundle incluye toda la información de preprocesamiento necesaria.

Pestaña Optimization (Optimización)

La pestaña Optimization (Optimización) utiliza optimización Bayesiana (Optuna) para encontrar los mejores hiperparámetros para tus modelos.

Selección de Modelo

Selecciona un solo modelo para optimizar del menú desplegable:

- Random Forest
- Gradient Boosting
- XGBoost
- LightGBM
- CatBoost
- SVR

Configuración de Optimización

- Number of Trials (Número de Pruebas): Cuántas combinaciones de hiperparámetros probar (10-500).
- Timeout (Tiempo Límite): Tiempo máximo de optimización en segundos (0 = sin límite).
- Enable Pruning (Habilitar Poda): Detener pruebas no prometedoras temprano (recomendado).

Rangos de Parámetros Personalizados

Haz clic en "Edit Parameter Ranges" (Editar Rangos de Parámetros) para personalizar el espacio de búsqueda. Para cada parámetro, puedes establecer Min Value (Valor Mín), Max Value (Valor Máx) y Type (Tipo - Entero o Flotante).

Parámetros Disponibles por Modelo

Modelo	Parámetros
Random Forest	n_estimators, max_depth, min_samples_split, min_samples_leaf
Gradient Boosting	n_estimators, max_depth, learning_rate, subsample
XGBoost	n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda
LightGBM	n_estimators, max_depth, learning_rate, num_leaves, subsample, colsample_bytree, reg_alpha, reg_lambda

Modelo	Parámetros
CatBoost	iterations, depth, learning_rate, l2_leaf_reg
SVR	C, epsilon, gamma

Haz clic en "Reset to Default" (Restablecer a Valor Predeterminado) para restaurar los rangos originales.

Proceso de Optimización

1. Selecciona el modelo y configura los ajustes
2. (Opcional) Edita los rangos de parámetros
3. Haz clic en "Start Optimization" (Iniciar Optimización)
4. Monitorea el progreso:
 - La barra de progreso muestra la prueba actual.
 - El registro muestra resultados de pruebas en tiempo real.

Resultados

Después de la optimización:

- Best Parameters (Mejores Parámetros): Valores óptimos de hiperparámetros encontrados.
- Best Score (Mejor Puntuación): Mejor rendimiento alcanzado.
- Number of Trials (Número de Pruebas): Total de pruebas completadas.
- Optimization Time (Tiempo de Optimización): Tiempo total transcurrido.
- Trial History Table (Tabla de Historial): Historial completo de todas las pruebas.

Guardando Modelos Optimizados

Haz clic en "Save Optimized Model" (Guardar Modelo Optimizado):

- Elige formato: Model Bundle (recomendado) o Legacy Format.
- Selecciona carpeta de destino.
- El modelo se guarda y aparece en la pestaña Results.

 **Pro Tip:** Comienza con 50 pruebas para exploración inicial. Aumenta a 100-200 para modelos de producción.

Pestaña Results (Resultados)

La pestaña Results (Resultados) muestra todos los modelos entrenados, optimizados y de conjunto.

Lista de Modelos

Todos los modelos se muestran en una tabla con:

- Model Name (Nombre del Modelo): Identificador.
- Type (Tipo): Trained (Entrenado), Optimized (Optimizado), Neural Network (Red Neuronal), o Ensemble (Conjunto).
- RMSE: Root Mean Squared Error.
- MAE: Mean Absolute Error.
- R^2 : Coeficiente de determinación.

Acciones

Para cada modelo, puedes:

- Details (Detalles): Ver información detallada sobre el modelo.
- Delete (Eliminar): Quitar el modelo de la lista.
- Export (Exportar): Guardar como model bundle o formato legacy.

Detalles del Modelo

Hacer clic en "Details" (Detalles) muestra:

- Tipo de modelo y fuente.
- Tiempo de entrenamiento/optimización.
- Todas las métricas de rendimiento.
- Mejores parámetros (para modelos optimizados).
- Importancia de características (si está disponible).
- Arquitectura de red neuronal (para modelos NN).

Curvas de Aprendizaje

Selecciona un modelo y haz clic en "Generate Learning Curves" (Generar Curvas de Aprendizaje) para visualizar la pérdida de entrenamiento vs validación a lo largo de las épocas. Esto ayuda a diagnosticar sobreajuste/subajuste.

Exportando Modelos

1. Selecciona el modelo del menú desplegable
2. Haz clic en "Export Model Bundle" (Exportar Bundle de Modelo)

3. Elige la carpeta de destino

4. El bundle contiene:

- manifest.json: Metadatos del modelo.
- pipeline.joblib o model.pt: Modelo entrenado.
- preprocessor.joblib: Pipeline de preprocesamiento (para NN).

Pestaña Ensemble (Conjunto)

La pestaña Ensemble (Conjunto) te permite combinar múltiples modelos para predicciones mejoradas.

Seleccionando Modelos

1. Haz clic en "Refresh Model List" (Actualizar Lista de Modelos) para cargar modelos disponibles
2. Selecciona múltiples modelos de la lista (Ctrl+Clic para múltiples)
3. Fuentes disponibles:
 - Modelos entrenados de la pestaña Training.
 - Modelos optimizados de la pestaña Optimization.

Configuración de Conjunto

Ensemble Type (Tipo de Conjunto)

- Averaging (Promedio): Media de todas las predicciones de modelos.
- Voting (Votación): Votación ponderada (para clasificación).
- Weighted (Ponderado): Promedio ponderado (pesos iguales por defecto).

Number of Models (Número de Modelos): Muestra cuántos modelos están seleccionados

Creando Conjunto

1. Selecciona 2 o más modelos
2. Elige el tipo de conjunto
3. Haz clic en "Create Ensemble" (Crear Conjunto)
4. Espera a que se complete la evaluación

Resultados del Conjunto

Después de la creación, verás:

- Ensemble Name (Nombre del Conjunto): Identificador generado automáticamente.
- Test Metrics (Métricas de Prueba): RMSE, MAE, R^2 en conjunto de prueba.
- Training Metrics (Métricas de Entrenamiento): RMSE, MAE, R^2 en conjunto de entrenamiento.

Guardando Conjuntos

Haz clic en "Save Ensemble Model" (Guardar Modelo de Conjunto):

- Elige formato (Bundle o Legacy).
- Selecciona carpeta de destino.

- El conjunto aparece en la pestaña Results y puede usarse en Explainability.

 **Pro Tip:** Los conjuntos funcionan mejor cuando combinas modelos con diferentes fortalezas. Intenta combinar un modelo basado en árboles (Random Forest) con un modelo de gradient boosting (XGBoost).

Pestaña Explainability (Explicabilidad)

La pestaña Explainability (Explicabilidad) proporciona herramientas de interpretación de modelos incluyendo valores SHAP, importancia por permutación y gráficos de dependencia parcial.

Selección de Modelo

1. Haz clic en "Refresh Model List" (Actualizar Lista de Modelos) para cargar modelos disponibles
2. Selecciona un modelo del menú desplegable
3. Modelos disponibles: Trained (Entrenado), Optimized (Optimizado), Neural Network (Red Neuronal), Ensemble (Conjunto)

Opciones de Análisis

Selecciona qué análisis ejecutar:

- Compute SHAP Values (Calcular Valores SHAP): Contribuciones de características usando SHAP.
- Compute Permutation Importance (Calcular Importancia por Permutación): Importancia de características vía permutación.
- Compute Partial Dependence Plots (Calcular Gráficos de Dependencia Parcial): Visualización de efecto de características.
- Analyze Domain Applicability (Analizar Aplicabilidad de Dominio): Análisis de cobertura de datos.

Número de Características

Establece cuántas características principales mostrar (1-100, por defecto: 10)

Ejecutando Análisis

1. Selecciona el modelo y opciones
2. Haz clic en "Run Explainability Analysis" (Ejecutar Análisis de Explicabilidad)
3. Monitorea el progreso en el área de registro
4. Los resultados aparecen en pestañas debajo

Pestañas de Resultados

Feature Importance (Importancia de Características)

Tabla mostrando:

- Feature (Característica): Nombre de la característica.
- Model Importance: Importancia integrada (si está disponible).
- Permutation: Puntuación de importancia por permutación.
- SHAP: Valor SHAP absoluto medio.

- Average Rank: Ranking combinado entre métodos.

 **Nota:** Para Redes Neuronales, Model Importance muestra "N/A" ya que no tienen importancia de características integrada.

SHAP Values (Valores SHAP)

Resumen del análisis SHAP:

- Importancia global de características (top N características).
- Valor SHAP absoluto medio por característica.

 **Nota:** Los valores SHAP se calculan usando KernelExplainer para compatibilidad universal entre todos los tipos de modelos.

Partial Dependence (Dependencia Parcial)

Lista de características analizadas con gráficos de dependencia parcial.

 **Nota:** Los Gráficos de Dependencia Parcial no están disponibles para Redes Neuronales debido a limitaciones de sklearn.

Domain Applicability (Aplicabilidad de Dominio)

Análisis del dominio de aplicabilidad del modelo:

- Training Samples: Número de muestras de entrenamiento.
- Original Features: Número de características de entrada.
- PCA Components: Número de componentes PCA usados.
- Explained Variance: Varianza capturada por PCA.
- Thresholds: Umbrales de Leverage, Mahalanobis, distancia k-NN.

Prediction Explanation (Explicación de Predicción)

Explica predicciones individuales:

- Ingresar el índice de instancia (número de fila).
- Haz clic en "Explain Prediction" (Explicar Predicción).
- Ver: Valor predicho, contribuciones SHAP (características principales), Principales contribuyentes positivos/negativos.

 **Materials Science Context:** Entender qué características impulsan las predicciones es crucial en ciencia de materiales. Por ejemplo, saber que las diferencias de electronegatividad influyen fuertemente en las predicciones de band gap puede guiar el diseño de materiales.

Pestaña Predict (Predicción)

La pestaña Predict (Predicción) te permite hacer predicciones sobre nuevos datos usando modelos guardados.

⚠ Importante: La pestaña Predict es un diferenciador clave de AutoAIM Studio. Habilita el modo de predicción independiente para desplegar modelos entrenados en nuevos materiales sin reentrenar.

Cargando un Modelo

1. Haz clic en "Load Model Bundle" (Cargar Bundle de Modelo)
2. Selecciona la carpeta que contiene:

- manifest.json (requerido)
- pipeline.joblib o model.pt (requerido)
- preprocessor.joblib (si aplica)

Se mostrará la información del modelo, incluyendo:

- Tipo de modelo y algoritmo.
- Nombres de características esperadas.
- Nombre de columna objetivo.
- Métricas del modelo (si están disponibles).

Cargando Datos de Predicción

1. Haz clic en "Load Prediction Data" (Cargar Datos de Predicción)
2. Selecciona tu archivo CSV o Excel
3. Aparecerá la vista previa de datos

Validación de Características

El sistema verifica si todas las características requeridas están presentes:

- Verde: Todas las características presentes.
- Amarillo: Las características faltantes pueden generarse automáticamente.
- Rojo: Las características faltantes no pueden generarse.

Auto-Generar Características

Si tus datos tienen una columna de fórmula (ej., "composition", "formula"):

- Marca "Auto-generate composition features from formula column if missing" (Auto-generar características de composición si faltan).
- El sistema generará 106 descriptores de composición automáticamente.

Haciendo Predicciones

1. Asegúrate de que todas las características requeridas estén presentes (estado verde)
2. Haz clic en "Make Predictions" (Hacer Predicciones)

Exportando Predicciones

1. Haz clic en "Export Predictions" (Exportar Predicciones)
 - Elige ubicación de guardado.
 - Las predicciones se guardan como CSV con todas las columnas originales más nueva columna de predicción.

 **Pro Tip:** Usa la pestaña Predict para filtrar grandes bases de datos de materiales. Entrena con un conjunto de datos pequeño bien caracterizado, luego predice propiedades para miles de materiales candidatos.

Solución de Problemas

Problemas Comunes

No se pueden generar características faltantes automáticamente

Causa: Faltan características de composición y no se detectó columna de fórmula

Solución:

- Asegúrate de que tus datos de predicción tengan una columna con fórmulas químicas.
- Marca la casilla "Auto-generate composition features."
- El nombre de la columna debe contener "formula", "composition" o "structure."

El modelo seleccionado no tiene método predict

Causa: El objeto del modelo está corrupto o no se cargó correctamente

Solución:

- Reentrena el modelo.
- Verifica si el modelo se guardó correctamente.
- Para Redes Neuronales, asegúrate de que el modelo se construyera antes de entrenar.

Modelo 'X' no encontrado en ninguna fuente

Causa: El modelo fue eliminado o no se almacenó correctamente

Solución:

- Reentrena el modelo.
- Guarda el modelo nuevamente después del entrenamiento.

Valores SHAP no disponibles para este modelo

Causa: El cálculo SHAP falló (usualmente para Redes Neuronales)

Solución:

- Asegúrate de que el modelo tenga un método predict funcional.
- Intenta con una muestra más pequeña del conjunto de datos.
- Verifica la consola para mensajes de error detallados.

Consejos de Rendimiento

Acelerar el Entrenamiento

- Reduce pliegues de CV: Usa 3 en lugar de 5.
- Usa GPU: Habilita aceleración GPU para Redes Neuronales.

- Reduce pruebas: Usa menos pruebas de optimización (20-30 en lugar de 50+).
- Muestrea datos: Entrena con un subconjunto para exploración inicial.

Mejorar la Precisión

- Genera características de composición: Usa los 106 descriptores.
- Optimiza hiperparámetros: Ejecuta optimización con más pruebas.
- Crea conjuntos: Combina múltiples modelos.
- Prueba diferentes algoritmos: No todos funcionan igual para todos los conjuntos de datos.

Reducir Uso de Memoria

- Deshabilita características de composición: Si no son necesarias.
- Reduce tamaño de lote: Para Redes Neuronales.
- Usa menos pruebas de optimización: Cada prueba mantiene resultados en memoria.

Obteniendo Ayuda

Si encuentras problemas no cubiertos aquí:

- Verifica la salida de registro en cada pestaña.
- Revisa la consola/terminal para mensajes de error detallados.
- Asegúrate de que tus datos estén correctamente formateados (CSV/Excel).
- Verifica que todas las columnas requeridas estén presentes.

Referencia de Características

Características de Composición (106 Descriptores)

El generador de características de composición personalizado calcula las siguientes estadísticas para cada fórmula química:

Propiedades Atómicas

- Número atómico (media, desv. est., mín, máx, rango, mediana, percentiles).
- Masa atómica (media, desv. est., mín, máx, rango, mediana, percentiles).
- Radio covalente (media, desv. est., mín, máx, rango, mediana, percentiles).
- Radio de Van der Waals (media, desv. est., mín, máx, rango, mediana, percentiles).

Propiedades Electrónicas

- Electronegatividad (media, desv. est., mín, máx, rango, mediana, percentiles).
- Energía de ionización (media, desv. est., mín, máx, rango, mediana, percentiles).
- Afinidad electrónica (media, desv. est., mín, máx, rango, mediana, percentiles).

Propiedades Físicas

- Densidad (media, desv. est., mín, máx, rango, mediana, percentiles).
- Punto de ebullición (media, desv. est., mín, máx, rango, mediana, percentiles).
- Punto de fusión (media, desv. est., mín, máx, rango, mediana, percentiles).

Propiedades de la Tabla Periódica

- Número de grupo (media, desv. est., mín, máx, rango, mediana, percentiles).
- Número de período (media, desv. est., mín, máx, rango, mediana, percentiles).

Características Adicionales

- Número de elementos únicos.
- Número total de átomos.
- Fracciones de elementos.

Estas características se calculan a partir de propiedades elementales y proporcionan una representación integral de la composición del material para modelos de machine learning.

 **Materials Science Context:** Los 106 descriptores capturan distribuciones estadísticas de propiedades elementales dentro de un compuesto. Por ejemplo, Fe_2O_3 generaría estadísticas basadas en las propiedades de Fe y O, ponderadas por sus relaciones estequiométricas.

Apéndice: Algoritmos de Modelos

Random Forest

- Tipo: Conjunto de árboles de decisión.
- Fortalezas: Maneja relaciones no lineales, robusto a valores atípicos.
- Mejor para: Regresión de propósito general, importancia de características.

Gradient Boosting

- Tipo: Conjunto secuencial.
- Fortalezas: Alta precisión, maneja patrones complejos.
- Mejor para: Precisión competitiva, conjuntos de datos medianos.

XGBoost

- Tipo: Gradient boosting optimizado.
- Fortalezas: Rápido, regularizado, maneja valores faltantes.
- Mejor para: Competiciones de datos tabulares, sistemas de producción.

LightGBM

- Tipo: Gradient boosting basado en histogramas.
- Fortalezas: Muy rápido, eficiente en memoria.
- Mejor para: Grandes conjuntos de datos, aplicaciones críticas de velocidad.

CatBoost

- Tipo: Gradient boosting con ordered boosting.
- Fortalezas: Excelente manejo categórico, reduce sobreajuste.
- Mejor para: Conjuntos de datos con muchas características categóricas.

SVR (Support Vector Regression)

- Tipo: Método basado en kernel.
- Fortalezas: Efectivo en altas dimensiones, eficiente en memoria.
- Mejor para: Conjuntos de datos pequeños a medianos, relaciones no lineales.

Ridge Regression

- Tipo: Regresión lineal con regularización L2.
- Fortalezas: Simple, rápido, previene sobreajuste.
- Mejor para: Modelo de línea base, relaciones lineales.

Redes Neuronales

- Tipo: Deep learning con arquitectura personalizable.
- Fortalezas: Aprende patrones no lineales complejos.
- Mejor para: Grandes conjuntos de datos, interacciones complejas de características.

Tarjeta de Referencia Rápida

Atajos de Teclado

Acción	Ubicación
Cargar Datos	Pestaña Data > Botón Load Data.
Preparar Datos	Pestaña Data > Botón Prepare Data.
Entrenar Modelos	Pestaña Training > Train Selected Models.
Guardar Modelo	Pestaña Results > Export Model Bundle.
Hacer Predicciones	Pestaña Predict > Make Predictions.

Guía de Problema-Solución

Si tienes este problema...	Haz esto...
El entrenamiento es muy lento	Reduce pliegues de CV o usa GPU.
Precisión del modelo pobre	Genera características de composición, prueba optimización.
Sin memoria	Reduce tamaño de lote, deshabilita características de composición.
Faltan características en Predict	Habilita auto-generar características de composición.
El modelo no carga	Verifica que manifest.json exista en la carpeta del bundle.

Cita y Licencia

Cómo Citar

Si usas AutoAIM Studio en tu investigación, por favor cita:

```
@software{autoaim_studio, title = {AutoAIM Studio: Automated Machine Learning for  
Materials Studio}, version = {1.0.0}, year = {2026}, url = {  
https://github.com/cesargabrielvera1-ux/AutoAIM-Studio.git} }
```

Licencia

AutoAIM Studio se distribuye bajo la Licencia MIT. Eres libre de usar, modificar y distribuir este software para fines académicos y comerciales.

Agradecimientos

AutoAIM Studio se basa en las siguientes bibliotecas de código abierto:

- scikit-learn: Algoritmos de machine learning.
- XGBoost: Framework de gradient boosting.
- LightGBM: Gradient boosting rápido.
- CatBoost: Boosting categórico.
- PyTorch: Framework de redes neuronales.
- Optuna: Optimización de hiperparámetros.
- SHAP: Interpretabilidad de modelos.
- pymatgen: Análisis de materiales.

AutoAIM Studio: Auto Artificial Intelligence for Materials

Versión 1.0.0 - Manual de Usuario

AutoAIM Studio

Machine Learning Automatizado para Ciencia de Materiales

veradelagarza@quimica.unam.mx

© 2026 AutoAIM Studio. Todos los derechos reservados.