



AutoAIM Studio

Inteligencia Artificial Automática para Materiales

Manual de Usuario

Versión 1.4.0

Nombre clave: "Control Total"

27 de junio de 2026

Contacto: veradelagarza@quimica.unam.mx

DOI: [10.5281/zenodo.20947495](https://doi.org/10.5281/zenodo.20947495)

Tabla de Contenido

1. Introducción

2. Primeros Pasos

2.1 Requisitos del Sistema

2.2 Instalación

2.3 Primer Inicio

3. Pestaña de Datos

3.1 Carga de Datos

3.2 Soporte de Estructuras Cristalinas

3.3 Feturización

3.4 Selección de Objetivo

3.5 División Entrenamiento/Prueba

4. Pestaña de Entrenamiento

4.1 Selección de Algoritmos

4.2 Validación Cruzada

4.3 Entrenar con Parámetros Personalizados

4.4 Entendiendo los Resultados

5. Pestaña de Optimización

5.1 Optimización Bayesiana

5.2 Seleccionar Parámetros a Optimizar

5.3 Resultados de Optimización

5.4 Entrenar con Mejores Parámetros

6. Pestaña de Redes Neuronales

6.1 Diseño de Arquitectura

6.2 Configuración de Entrenamiento

6.3 Optimización de RN

6.4 Resultados de Entrenamiento

7. Pestaña de Ensamblado

7.1 Creación de Ensamblados

7.2 Pesos Manuales de Ensamblado

7.3 Optimización de Pesos

8. Pestaña de Resultados

9. Pestaña de Explicabilidad

10. Pestaña de Predicción

11. Paquetes de Modelos

12. Solución de Problemas

13. Historial de Versiones

14. Citación

1. Introducción

AutoAIM Studio es una aplicación de escritorio independiente para aprendizaje automático en ciencia de materiales y más allá. Proporciona un pipeline AutoML completo sin código con ingeniería de características composicionales personalizadas, análisis de estructuras cristalinas, diseño de redes neuronales, optimización de hiperparámetros, configuración manual de parámetros, selección de parámetros para optimización y despliegue de modelos.

Este manual cubre todas las características de AutoAIM Studio v1.4.0 (nombre clave "Control Total"), lanzado el 27 de junio de 2026. Ya sea que esté prediciendo propiedades de materiales a partir de fórmulas químicas, analizando estructuras cristalinas o diseñando redes neuronales para tareas de regresión complejas, esta guía le llevará a través de cada paso.

Materials Science Context: La informática de materiales combina la ciencia de materiales con el aprendizaje automático para acelerar el descubrimiento y optimización de nuevos materiales. AutoAIM Studio cierra la brecha entre la experiencia del dominio y la implementación de ML, permitiendo a los investigadores centrarse en la ciencia en lugar del código.

Pro Tip: Si es nuevo en AutoAIM Studio, comience con la Guía de Inicio Rápido en la Sección 2, luego siga el recorrido pestaña por pestaña en las Secciones 3-10.

Note: Para soporte o preguntas, contáctenos en veradelagarza@quimica.unam.mx

2. Primeros Pasos

2.1 Requisitos del Sistema

Componente	Mínimo	Recomendado
SO	Windows 10/11 (64-bit)	Windows 11 (64-bit)
CPU	4 núcleos	8+ núcleos
RAM	8 GB	16 GB+
Disco	2 GB libres	5 GB libres
GPU	No requerida	Opcional (CUDA para aceleración de RN)
Pantalla	1280x720	1920x1080 o superior

Note: El ejecutable compilado con PyInstaller es solo-CPU. Para soporte GPU con aceleración CUDA de PyTorch, ejecute AutoAIM Studio desde código fuente con un entorno Python con capacidad CUDA.

2.2 Instalación

Windows (Ejecutable Pre-compilado):

1. Descargue AutoAIM-Studio-v1.4.0-Windows.zip de la página de lanzamientos
2. Extraiga en su ubicación preferida
3. Ejecute MaterialsAutoML.exe

No se requiere instalación de Python. Todas las dependencias están incluidas.

Desde Código Fuente:

```
git clone https://github.com/yourusername/materials_automl.git
cd materials_automl
pip install -r requirements.txt
python main_executable.py
```

2.3 Primer Inicio

Cuando lanza AutoAIM Studio por primera vez, la aplicación inicializa su espacio de trabajo y verifica las dependencias requeridas. La ventana principal se abre con la pestaña de Datos activa, mostrando un conjunto de datos vacío listo para cargar.

Pro Tip: En la primera ejecución con archivos de estructura cristalina, los datos de pymatgen se descargan automáticamente. Asegúrese de tener una conexión a Internet activa para esta configuración única.

3. Pestaña de Datos

La pestaña de Datos es su punto de partida para cualquier flujo de trabajo en AutoAIM Studio. Aquí carga conjuntos de datos, aplica feturización, selecciona su variable objetivo y configura la división entrenamiento/prueba. AutoAIM Studio soporta archivos CSV con fórmulas químicas y archivos de estructura cristalina (CIF, POSCAR, XYZ).

3.1 Carga de Datos

Archivos CSV:

- Haga clic en "Load CSV" para importar un conjunto de datos. El archivo debe contener una columna objetivo (la propiedad que desea predecir) y al menos una columna de características o una columna de fórmula/composición para feturización.
- Formatos soportados: .csv, .xlsx, .xls, .parquet, .json
- Las columnas de texto (composición, rutas de archivos, IDs) se excluyen automáticamente de las características

Archivos de Estructura Cristalina:

- Haga clic en "Load Directory" para importar todos los archivos de estructura de una carpeta
- Haga clic en "Load Files" para selección individual
- Formatos soportados: CIF, POSCAR, CONTCAR, VASP, XYZ

Formato	Extensión	Descripción
CIF	.cif	Archivo de Información Cristalográfica
POSCAR	.poscar	Archivo de posiciones VASP
CONTCAR	.contcar	Archivo de continuación VASP
XYZ	.xyz	Coordenadas cartesianas
VASP	.vasp	Formato VASP genérico

Materials Science Context: Los archivos de estructura cristalina contienen posiciones atómicas 3D e información de la red. Al cargarlos, AutoAIM extrae automáticamente aproximadamente 154 descriptores numéricos por estructura, incluyendo parámetros de red, estadísticas de composición, descriptores Magpie, análisis de enlaces y picos de función de distribución radial.

3.2 Soporte de Estructuras Cristalinas

AutoAIM Studio v1.2.0+ proporciona soporte completo para estructuras cristalinas. Cuando carga archivos de estructura, la aplicación extrae automáticamente características numéricas:

Categoría	Cantidad	Ejemplos
Red	~10	a, b, c, alpha, beta, gamma, volumen, banderas de simetría
Composición	~13	número atómico promedio, electronegatividad, radii, energía de ionización
Estructural	~3	volumen_por_atomo, fracción_empaque, número_grupo_espacial
Magpie	106	media/desv/min/max/mediana/p25/p75 para 13 propiedades elementales
Avanzado	~15	longitudes de enlace, números de coordinación, picos RDF, anisotropía
Derivado	~2	densidad, electrones_totales

Note: El feturizador manual (botón "Apply Featurizer") está diseñado para archivos CSV con una columna de fórmula o composición. Los conjuntos de datos de estructura cristalina ya están completamente feturizados al cargarse.

3.3 Feturización

Para conjuntos de datos CSV que contienen fórmulas químicas o cadenas de composición, AutoAIM Studio proporciona feturización composicional personalizada que genera 106 descriptores Magpie sin requerir MatMiner.

Para aplicar feturización:

4. Cargue su archivo CSV (asegúrese de tener una columna 'formula' o 'composition')
5. Haga clic en "Apply Featurizer"
6. La aplicación genera 106 descriptores

Pro Tip: Para conjuntos de datos de estructura cristalina, al hacer clic en "Apply Featurizer" se muestra un diálogo informativo explicando que ~154 características ya están presentes.

3.4 Selección de Objetivo

Después de cargar los datos, debe seleccionar la columna objetivo. Al cargar un CSV de objetivos para estructuras cristalinas, un diálogo le permite seleccionar qué columna numérica es la propiedad a predecir. Todas las demás columnas se descartan automáticamente.

Important: Solo las columnas numéricas pueden usarse como características u objetivos. Las columnas de texto se excluyen automáticamente y se registran para su referencia.

3.5 División Entrenamiento/Prueba

Configure cómo se dividen sus datos:

- Test Size: Porcentaje de datos reservados para pruebas (predeterminado: 20%)
- Random State: Semilla para divisiones reproducibles. Cambiar este valor ahora produce resultados genuinamente diferentes (corrección v1.4.0)
- Validación Externa: Cargue un conjunto de validación separado para evaluación independiente

Note: En v1.4.0, la funcionalidad de estado aleatorio fue completamente corregida. La división entrenamiento/prueba usa la semilla de Parámetros Personalizados, KFold CV usa el random_state del modelo, y NN CV usa TrainingConfig.random_seed.

4. Pestaña de Entrenamiento

La pestaña de Entrenamiento es donde entrena múltiples algoritmos de aprendizaje automático simultáneamente. AutoAIM Studio soporta siete algoritmos de regresión con validación cruzada.

4.1 Selección de Algoritmos

Algoritmo	Tipo	Características Clave
Random Forest	Ensamblado (bagging)	Robusto, maneja bien relaciones no lineales
Gradient Boosting	Ensamblado (boosting)	Corrección secuencial de errores, alta precisión
XGBoost	Gradient boosting	Implementación optimizada, regularización
LightGBM	Gradient boosting	Crecimiento por hojas, entrenamiento rápido
CatBoost	Gradient boosting	Maneja características categóricas nativamente
SVR	Método de kernel	Efectivo en espacios de alta dimensionalidad
k-NN	Basado en instancias	Simple, interpretable

Pro Tip: Para la mayoría de conjuntos de datos de ciencia de materiales, recomendamos comenzar con Random Forest, XGBoost y LightGBM. Estos métodos basados en árboles manejan las relaciones no lineales comunes en datos de materiales.

4.2 Validación Cruzada

La validación cruzada proporciona estimaciones robustas de rendimiento entrenando en múltiples divisiones de datos. Configure el número de folds (1-10) en la pestaña de Entrenamiento.

- CV = 1: División única entrenamiento/prueba (más rápido)
- CV = 5: Validación cruzada 5-fold (recomendado)
- CV = 10: Validación cruzada 10-fold (más robusto)

4.3 Entrenar con Parámetros Personalizados

La función "Train with Custom Parameters" le permite configurar manualmente los hiperparámetros de cualquier regresor y entrenar directamente, sin pasar por la optimización Bayesiana.

Para usar Parámetros Personalizados:

7. Seleccione un algoritmo del menú desplegable
8. Haga clic en "Train with Custom Parameters"
9. Configure los parámetros en el diálogo

10. Establezca Random State y n_jobs para reproducibilidad

11. Haga clic en "Train"

Algoritmo	Parámetros
Random Forest	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features
Gradient Boosting	n_estimators, max_depth, learning_rate, subsample, min_samples_split, min_samples_leaf
XGBoost	n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda, min_child_weight, gamma
LightGBM	n_estimators, max_depth, learning_rate, num_leaves, subsample, colsample_bytree, reg_alpha, reg_lambda, min_child_samples
CatBoost	iterations, depth, learning_rate, l2_leaf_reg
SVR	C, epsilon, gamma (scale/auto/número), kernel (linear/poly/rbf/sigmoid)
Ridge	alpha

Important: En v1.4.0, el diálogo de Parámetros Personalizados soporta 10-12 decimales (era 6-8) para pruebas de sensibilidad de alta precisión. Además, todos los parámetros configurables manualmente ahora están incluidos en la optimización Bayesiana.

Pro Tip: La función de Entrada de Alta Precisión (v1.4.0) le permite ingresar valores como 0.0000001 para parámetros como min_delta, permitiendo pruebas de sensibilidad fina que no eran posibles con el límite anterior de 6-8 decimales.

4.4 Entendiendo los Resultados

Después del entrenamiento, la pestaña de Resultados muestra:

- Nombre del modelo y tipo de algoritmo
- Métricas R2, RMSE, MAE y MAPE
- Puntuación CV (puntuación media de validación cruzada)
- Desglose de puntuaciones CV por fold (haga clic en "Details")
- Tiempo de entrenamiento

5. Pestaña de Optimización

La pestaña de Optimización proporciona optimización Bayesiana de hiperparámetros usando Optuna. Esta potente función busca automáticamente la mejor combinación de hiperparámetros para su algoritmo seleccionado.

5.1 Optimización Bayesiana

Para ejecutar la optimización:

- 12. Seleccione el algoritmo a optimizar
- 13. Configure el número de ensayos de Optuna
- 14. Opcionalmente establezca rangos de parámetros personalizados
- 15. Haga clic en "Optimize"

Materials Science Context: La optimización Bayesiana construye un modelo probabilístico de la función objetivo (rendimiento del modelo) y lo usa para seleccionar los hiperparámetros más prometedores para evaluar a continuación. Esto es mucho más eficiente que búsqueda en cuadrícula o aleatoria.

5.2 Seleccionar Parámetros a Optimizar

Nuevo en v1.4.0, la función "Select Parameters to Optimize" es la adición más impactante para usuarios de CPU. Ahora puede elegir qué hiperparámetros optimizará Optuna, con un preajuste "Recommended" que selecciona solo parámetros de alto impacto para una optimización más rápida.

El diálogo proporciona:

- Casilla de verificación para cada parámetro de cada modelo
- "Select All" - optimiza todo (comportamiento predeterminado)
- "Select Recommended" - solo parámetros de alto impacto (más rápido en CPU)
- "Clear All" - comience desde cero
- Tooltips educativos en cada parámetro explicando su nivel de impacto

Modo	Descripción	Mejor Para
Select All	Cada parámetro se optimiza	Máxima precisión, usuarios GPU
Select Recommended	Solo parámetros de alto impacto	Optimización más rápida, usuarios CPU
Clear All + Custom	Selección manual de parámetros específicos	Optimización dirigida, usuarios expertos

Pro Tip: Para optimización basada en CPU, use el modo 'Select Recommended'. Esto típicamente reduce el espacio de búsqueda en un 40-60% manteniendo el 95%+ de la mejora potencial de rendimiento.

Important: La función Select Parameters to Optimize está disponible tanto para optimización de regresores (pestaña Optimization) como para optimización de arquitectura de RN (pestaña NN). En v1.4.0, min_child_samples de LightGBM fue añadido, llevándolo a 9 parámetros ajustables igualando la cobertura de XGBoost.

Algoritmo	# Parámetros	Parámetros Optimizados
Random Forest	5	n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features
Gradient Boosting	6	n_estimators, max_depth, learning_rate, subsample, min_samples_split, min_samples_leaf
XGBoost	9	n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda, min_child_weight, gamma
LightGBM	9	n_estimators, max_depth, learning_rate, num_leaves, subsample, colsample_bytree, reg_alpha, reg_lambda, min_child_samples
CatBoost	4	iterations, depth, learning_rate, l2_leaf_reg
SVR	4	C, epsilon, gamma, kernel (categórico)
Ridge	1	alpha

5.3 Resultados de Optimización

La pestaña de resultados de optimización proporciona un diseño limpio de 4 columnas mostrando Rank, Score, Parameters y Trial#. Las puntuaciones CV por fold se muestran en el panel "Best Trial Details".

5.4 Entrenar con Mejores Parámetros

Después de la optimización, haga clic en "Train with Best Parameters" para entrenar inmediatamente un modelo usando los mejores hiperparámetros encontrados.

6. Pestaña de Redes Neuronales

La pestaña de Redes Neuronales proporciona una interfaz visual para diseñar y entrenar arquitecturas PyTorch personalizadas. Puede agregar capas, configurar activaciones, establecer parámetros de entrenamiento y optimizar toda la arquitectura usando optimización Bayesiana.

6.1 Diseño de Arquitectura

Construya su red agregando y configurando capas:

- Dense (Linear): Capas completamente conectadas
- Dropout: Capa de regularización que previene sobreajuste
- BatchNorm: Normaliza entradas de capa para estabilizar el entrenamiento
- Activación: ReLU, LeakyReLU, GELU, Sigmoid, Tanh o ELU

Pro Tip: Para predicción de propiedades de materiales, recomendamos comenzar con 2-3 capas ocultas de 64-128 unidades cada una, con activación ReLU y dropout 0.2-0.3 entre capas.

6.2 Configuración de Entrenamiento

Parámetro	Descripción	Rango
Epochs	Número de iteraciones de entrenamiento	10-10,000
Learning Rate	Tamaño de paso para descenso de gradiente	1e-5 a 1.0
Batch Size	Muestras por actualización de gradiente	8-512
Optimizer	Algoritmo de optimización	Adam, SGD, AdamW, RMSprop
LR Scheduler	Estrategia de ajuste de tasa de aprendizaje	reduce_on_plateau, cosine_annealing, step_lr, exponential, none
Min Delta	Umbral mínimo de mejora para early stopping	1e-6 a 0.1 (predet: 1e-4)
Gradient Clip	Norma máxima de gradiente	0 a 10 (predet: 1.0, 0 = desactivado)

CV Folds	Folds de validación cruzada	1-10
Random Seed	Semilla de reproducibilidad	Cualquier entero

6.3 Optimización de RN

La optimización Bayesiana para redes neuronales busca a través de la arquitectura e hiperparámetros de entrenamiento simultáneamente. En v1.4.0, puede usar Select Parameters to Optimize para enfocar la búsqueda en parámetros específicos.

Parámetros optimizables:

- Layers: Número de capas ocultas (1-5)
- Units: Neuronas por capa (16-256)
- Dropout: Tasa de dropout (0.0-0.5)
- Activation: ReLU, LeakyReLU, GELU, ELU
- Learning Rate (escala log)
- Batch Size: 16, 32, 64, 128, 256 (categórico)
- Optimizer: Adam, SGD, AdamW (categórico)
- Gradient Clip Val: 0.0-5.0

6.4 Resultados de Entrenamiento

Nuevo en v1.4.0, la tabla de Resultados de Entrenamiento en la pestaña NN ahora muestra datos epoch por epoch con Train Loss, Val Loss, Train Metric, Val Metric y Time para cada epoch.

Pro Tip: La pestaña NN fue rediseñada en v1.4.0 con diseño compacto: Actions + Presets fusionados en una sola barra de herramientas, los 4 paneles derechos tienen altura limitada, y más espacio horizontal para el panel de configuración.

7. Pestaña de Ensamblado

La pestaña de Ensamblado le permite combinar múltiples modelos entrenados para obtener predicciones mejoradas. AutoAIM soporta estrategias de promedio ponderado y stacking, con optimización Bayesiana opcional de pesos de miembros.

7.1 Creación de Ensamblados

Para crear un ensamblado:

16. Entrene dos o más modelos individuales en la pestaña de Entrenamiento
17. Cambie a la pestaña de Ensamblado
18. Seleccione los modelos a incluir
19. Elija estrategia: Weighted Average o Stacking

20. Configure folds de CV para evaluación del ensamblado

21. Haga clic en "Train Ensemble"

Important: En v1.4.0, dos errores críticos de ensamblado fueron corregidos: (1) Resultados de ensamblado no apareciendo en la pestaña de Resultados - causado por llamar a `get_ensemble_trainer()` que no existía. (2) Resultados de ensamblado duplicados - código que guardaba en ambas ubicaciones.

7.2 Pesos Manuales de Ensamblado

El panel de Manual Weights le permite establecer pesos personalizados para cada modelo en un ensamblado de promedio ponderado. Si no se establecen pesos manuales, el sistema usa pesos iguales.

7.3 Optimización de Pesos

Haga clic en "Optimize Weights" para ejecutar optimización Bayesiana en las contribuciones de miembros del ensamblado. Optuna busca la combinación de pesos óptima que maximiza el rendimiento.

8. Pestaña de Resultados

La pestaña de Resultados proporciona una visión general de todos los modelos entrenados, incluyendo regresores, ensamblados y redes neuronales. La interfaz rediseñada deduplica resultados por nombre antes de renderizar la tabla de comparación.

Para cada modelo, puede ver:

- Nombre del modelo y tipo de algoritmo
- Métricas R2, RMSE, MAE, MAPE
- Puntuación CV con desglose por fold
- Tiempo de entrenamiento y estado

Acciones disponibles:

- Delete: Eliminar un modelo (v1.4.0: ahora busca también en `training_tab.training_results`)
- Export: Guardar modelo como `.joblib` o `.pt`
- Details: Ver puntuaciones CV por fold y métricas detalladas
- Create Bundle: Empaquetar modelo para despliegue independiente

9. Pestaña de Explicabilidad

La pestaña de Explicabilidad proporciona herramientas de interpretación de modelos para entender qué características impulsan sus predicciones.

Análisis disponibles:

- SHAP Summary Plot: Importancia global de características basada en valores SHAP
- Permutation Importance: Importancia medida al barajar valores
- Partial Dependence: Cómo cambian las predicciones al variar una característica
- Individual Predictions: Gráficos de fuerza SHAP para predicciones individuales

Materials Science Context: Los valores SHAP provienen de la teoría de juegos cooperativos y proporcionan una forma teóricamente sólida de atribuir predicciones a características. Una característica con alta importancia SHAP influye consistentemente en las predicciones del modelo.

10. Pestaña de predicción

La pestaña Predict permite la predicción independiente usando modelos entrenados sin la aplicación completa. Puede cargar un Model Bundle o un archivo de modelo entrenado y hacer predicciones sobre nuevos datos.

Para predicción de estructuras cristalinas (v1.2.0+):

- Cargue archivos CIF, POSCAR o XYZ directamente
- Las estructuras se feturizan automáticamente
- No se requiere metadata CSV externa
- Las exportaciones de predicción preservan structure_name como primera columna

11. Paquetes de Modelos

Los Model Bundles son paquetes autocontenidos que incluyen todo lo necesario para predicción independiente. Cada bundle contiene el modelo entrenado, pipeline de preprocesamiento, lista de características y un manifest.json con metadata completa.

Para crear un Model Bundle:

22. Entrene un modelo en la pestaña de Entrenamiento u Optimización
23. En la pestaña de Resultados, haga clic en "Create Bundle"
24. Elija la ubicación de salida
25. El bundle .zip se crea con todos los archivos necesarios

Important: En v1.3.0+, el error de guardado de bundles con GPU fue corregido. La conversión TorchScript ahora mueve el modelo a CPU antes del tracing. Si TorchScript falla, se guarda el nn.Module completo como respaldo.

12. Solución de Problemas

Esta sección cubre problemas comunes y sus soluciones. Para soporte adicional, contáctenos en veradelagarza@quimica.unam.mx

Problema	Solución
Resultados de ensamblado no aparecen	Corregido en v1.4.0. Actualice a la última versión.
Modelos manuales no se pueden eliminar	Corregido en v1.4.0. Delete ahora busca también en <code>training_tab.training_results</code> .
SVR Gamma Crash: 'could not convert string'	Corregido en v1.3.0. Gamma ahora es combo box con 'scale', 'auto' o valor numérico.
CatBoost 'random_seed, random_state'	Corregido en v1.3.0. Parámetros Personalizados detecta CatBoost y usa <code>random_seed</code> .
PyInstaller 'periodic_table.json.gz'	Corregido en v1.2.0. Hook de tiempo de ejecución configura <code>PMG_HOME</code> automáticamente.
Explosión de características (771+)	Corregido en v1.2.0. Solo columnas numéricas se usan como características.
Conjuntos grandes causando problemas de RAM	Reduzca el tamaño del conjunto o aumente la RAM del sistema.
GPU no detectada para entrenamiento RN	Ejecute desde código fuente con PyTorch CUDA. El ejecutable PyInstaller es solo-CPU.
Optimización lenta en CPU	Use el modo 'Select Recommended' en v1.4.0 para reducir el espacio de búsqueda.
Cambios de random state no afectan resultados	Corregido en v1.4.0. Todos los tipos de modelo ahora usan semillas aleatorias configurables.

12.1 Reporte de Errores

En v1.4.0, todos los hilos de entrenamiento y optimización ahora incluyen traceback completo en los mensajes de error. Además, el helper `_safe_get_parent_attr()` reemplaza aproximadamente 50 accesos directos `self.parent.*` en todas las pestañas GUI, previniendo crashes por condiciones de carrera.

12.2 Logging

En v1.4.0, todas las llamadas `print()` fueron reemplazadas con logging apropiado (`logger.info/debug/warning/error`) en toda la GUI. Los logs se escriben en el directorio de la aplicación y pueden ayudar a diagnosticar problemas.

13. Historial de Versiones

Versión	Fecha	Nombre Clave	Características Principales
---------	-------	--------------	-----------------------------

1.4.0	2026-06-27	Control Total	Select Parameters to Optimize, corrección Random State, Entrada de Alta Precisión, min_child_samples LightGBM, rediseño NN Tab, resultados de entrenamiento, correcciones ensamblado, acceso seguro a padre, logging unificado
1.3.0	2026-06-24	Precisión	Parámetros Personalizados (7 regresores), Pesos Manuales Ensamblado, 53 tooltips, desglose CV, LR Scheduler/Min Delta/Gradient Clip, estado post-optimización NN, reordenamiento pestañas
1.2.0	2026-06-14	Cristal	Soporte Estructuras Cristalinas (CIF/POSCAR/XYZ), ~154 descriptores, corrección SVR/KNN, corrección PyInstaller
1.1.0	2026-05-18	Fundación	Optimización NN, CV para todos los modelos, Optimización Pesos Ensamblado
1.0.0	2026-04-08	Génesis	Lanzamiento estable inicial, pipeline AutoML, feturización composicional, Model Bundles

14. Citación

Si usa AutoAIM Studio en su investigación, por favor cite:

```
@software{autoaim_studio_2026,  
  title = {AutoAIM Studio: Auto Artificial Intelligence for Materials},  
  version = {1.4.0},  
  year = {2026},  
  doi = {10.5281/zenodo.20947495},  
  url = {https://github.com/cesargabrielvera1-ux/AutoAIM-Studio}  
}
```

Contacto: veradelagarza@quimica.unam.mx

DOI: 10.5281/zenodo.20947495

¡Gracias por usar AutoAIM Studio! Esperamos que esta herramienta acelere su descubrimiento de materiales e investigación. Para preguntas, sugerencias o reportes de errores, por favor contáctenos en el correo anterior.