



**AutoAIM
Studio**

AutoAIM Studio

Manual de Usuario

Machine Learning Automatizado para Ciencia de Materiales

César Gabriel Vera de la Garza & Serguei Fomine

Versión 1.1.0 | 2026

Nuevo Lanzamiento

Índice de Contenidos

Introducción	3
Primeros Pasos	4
Pestaña Data (Datos)	5
Pestaña Training (Entrenamiento)	7
Pestaña Neural Network (Red Neuronal)	9
Pestaña Optimization (Optimización)	12
Pestaña Results (Resultados)	14
Pestaña Ensemble (Conjunto)	16
Pestaña Explainability (Explicabilidad)	17
Pestaña Predict (Predicción)	19
Solución de Problemas	21
Referencia de Características	23
Apéndice: Algoritmos de Modelos	24
Tarjeta de Referencia Rápida	26
Cita y Licencia	27

Introducción

AutoAIM Studio es una plataforma integral de machine learning diseñada para aplicaciones de ciencia de materiales. Proporciona una interfaz gráfica intuitiva para preprocesamiento de datos, entrenamiento de modelos, optimización de hiperparámetros, construcción de redes neuronales, modelado por conjuntos e interpretación de modelos.

Características Principales

- Preprocesamiento Automático de Datos: Manejo de valores faltantes, codificación categórica y escalado de características.
- Ingeniería de Características de Composición: Genera 106 descriptores basados en composición a partir de fórmulas químicas.
- Múltiples Algoritmos de ML: Random Forest, Gradient Boosting, XGBoost, LightGBM, CatBoost, SVR, Ridge.
- Constructor de Redes Neuronales: Diseño visual de arquitectura con capas personalizables y optimización de hiperparámetros.
- Optimización de Hiperparámetros: Optimización Bayesiana con Optuna para regresores y redes neuronales.
- Modelado por Conjuntos: Combina múltiples modelos con optimización de pesos para mejorar predicciones.
- Interpretabilidad de Modelos: Valores SHAP, importancia por permutación, gráficas de dependencia parcial.
- Modo de Predicción Independiente: Despliega modelos entrenados para inferencia en nuevos datos.

Requisitos del Sistema

 **Nota:** Asegúrese de que su sistema cumpla estos requisitos para un rendimiento óptimo.

- Windows 10/11 (64-bit).
- 8GB RAM mínimo (16GB recomendado).
- GPU compatible con CUDA (opcional, para aceleración de redes neuronales).

Primeros Pasos

Lanzar la Aplicación

1. Haga doble clic en el archivo `AutoAIM Studio.exe`. La carpeta “_internal” debe encontrarse en el mismo directorio.
2. La ventana principal se abrirá con múltiples pestañas en la parte superior.
3. Comience cargando sus datos en la pestaña Data.

Flujo de Trabajo General

El flujo de trabajo típico sigue estos pasos:

- Cargar Datos → Pestaña Data.
- Preprocesar → Pestaña Data (manejar valores faltantes, codificar categóricas).
- Generar Características → Pestaña Data (opcional, descriptores de composición).
- Entrenar Modelos → Pestaña Training o Neural Network.
- Optimizar → Pestaña Optimization (opcional, ajuste de hiperparámetros).
- Crear Conjuntos → Pestaña Ensemble (opcional, combinar modelos).
- Analizar Resultados → Pestaña Results.
- Interpretar Modelos → Pestaña Explainability.
- Hacer Predicciones → Pestaña Predict.

 **Pro Tip:** Comience con un conjunto de datos pequeño para familiarizarse con el flujo de trabajo antes de procesar conjuntos grandes.

Pestaña Data (Datos)

La pestaña Data es su punto de partida para cargar y preparar su conjunto de datos.

Cargar Datos

1. Haga clic en el botón **"Load Data"**.
2. Seleccione su archivo de datos (formato CSV o Excel soportado).
3. La vista previa de datos aparecerá en la tabla inferior.

Formatos Soportados

- Archivos CSV (.csv).
- Archivos Excel (.xlsx, .xls).

Vista Previa de Datos

Después de cargar, verá:

- Shape: Número de filas y columnas.
- Columns: Lista de todos los nombres de columnas.
- Data Types: Detección automática de columnas numéricas y categóricas.
- Sample Data: Primeras filas de su conjunto de datos.

Selección de Columna Objetivo

1. Seleccione su variable objetivo del desplegable **"Target Column"**.
2. El sistema detectará automáticamente si es un problema de regresión o clasificación.

Opciones de Preprocesamiento

Manejar Valores Faltantes

Casilla: **"Handle missing values"**. Cuando está habilitada, los valores numéricos faltantes se imputan con la mediana. Los valores categóricos faltantes se imputan con el valor más frecuente.

Codificar Variables Categóricas

Casilla: **"Encode categorical variables"**. Cuando está habilitada, las variables categóricas se codifican con one-hot encoding. Esto expande las columnas categóricas en múltiples columnas binarias.

Escalar Características

Casilla: **"Scale features"**. Cuando está habilitada, las características se estandarizan (media cero, varianza unitaria). Recomendado para algoritmos sensibles a la escala (SVR, Redes Neuronales).

Generar Características de Composición

Casilla: "Generate composition features (106 descriptors)". **Requiere:** Una columna con fórmulas químicas (por ejemplo, "Fe2O3", "SiO2"). Cuando está habilitada, el sistema extrae 106 descriptores basados en composición incluyendo:

- Estadísticas de número atómico (media, std, min, max).
- Estadísticas de masa atómica.
- Estadísticas de electronegatividad.
- Estadísticas de radio covalente.
- Estadísticas de energía de ionización.
- Y muchas más propiedades de materiales.

 **Contexto para la ciencia de materiales:** El generador de características de composición es una implementación personalizada diseñada para aplicaciones de ciencia de materiales. Analiza fórmulas químicas y calcula estadísticas agregadas basadas en propiedades elementales.

Preparar Datos

Después de configurar las opciones:

1. Haga clic en el botón "Prepare Data".
2. El sistema dividirá los datos en conjuntos de entrenamiento/prueba (80/20 por defecto).
3. Se aplicarán todos los pasos de preprocesamiento seleccionados.
4. Aparecerá un mensaje de confirmación al completar.

Pestaña Training (Entrenamiento)

La pestaña Training le permite entrenar múltiples modelos de machine learning simultáneamente.

Selección de Modelos

Seleccione uno o más modelos de la lista:

Random Forest: Conjunto de árboles de decisión, bueno para predicción de propósito general.

Gradient Boosting: Conjunto secuencial, a menudo logra alta precisión.

XGBoost: Gradient boosting optimizado, estándar de la industria.

LightGBM: Gradient boosting rápido con crecimiento por hojas.

CatBoost: Gradient boosting optimizado para características categóricas.

SVR: Support Vector Regression, bueno para conjuntos más pequeños.

Ridge: Regresión lineal con regularización L2, línea base simple.

Configuración de Entrenamiento

- Problem Type: Detectado automáticamente (regresión/clasificación).
- Cross-Validation Folds: Número de pliegues CV para evaluación (predeterminado: 5).
- Random State: Semilla para reproducibilidad (predeterminado: 42).

Proceso de Entrenamiento

1. Seleccione los modelos deseados (marque las casillas).
2. Haga clic en "Train Selected Models".
3. El progreso se mostrará en la barra de estado.
4. Los resultados aparecerán automáticamente en la pestaña Results.

Entendiendo los Resultados

Después del entrenamiento, cada modelo muestra:

- RMSE: Error Cuadrático Medio (menor es mejor).
- MAE: Error Absoluto Medio (menor es mejor).
- R²: Coeficiente de determinación (mayor es mejor, máximo 1.0).
- Training Time: Tiempo que duró el entrenamiento.
- CV Score: Media $\pm$ desv. std. del score de validación cruzada.

⚡ **Pro Tip:** Para conjuntos de datos de ciencia de materiales, recomendamos comenzar con Random Forest y XGBoost, ya que suelen ofrecer el mejor equilibrio entre precisión e interpretabilidad.

Pestaña Neural Network (Red Neuronal)

La pestaña Neural Network proporciona una interfaz visual para diseñar y entrenar redes neuronales personalizadas, ahora con soporte completo de optimización de hiperparámetros.

Diseño de Arquitectura

Número de Capas Ocultas

Use el cuadro de número para establecer 1-5 capas ocultas. Cada capa se puede configurar independientemente.

Configuración de Capas

Para cada capa oculta, puede establecer:

- Units: Número de neuronas (16-2048).
- Activation Function: ReLU, Leaky ReLU, Tanh, Sigmoid, GELU, ELU.
- Dropout Rate: Regularización (0.0-0.5).
- Batch Normalization: Habilitar/deshabilitar batch normalization.

Vista Previa de Arquitectura

Haga clic en "Update Architecture Preview" para ver:

- Dimensiones de la capa de entrada.
- Configuraciones de capas ocultas.
- Dimensiones de la capa de salida.
- Número total de parámetros.
- Parámetros entrenables.

Configuración de Entrenamiento

Parámetro	Descripción	Rango
Epochs	Número de iteraciones de entrenamiento	10-10,000
Batch Size	Muestras por actualización de gradiente	8-512
Learning Rate	Tamaño de paso para optimización	0.00001-0.1
Optimizer	Algoritmo de optimización	Adam, AdamW, SGD, RMSprop
Weight Decay (L2)	Fuerza de regularización	0.0-0.1

Parámetro	Descripción	Rango
Early Stopping Patience	Detener si no hay mejora	5-500 epochs
CV Folds	Pliegues de validación cruzada K-fold	1-10 (predet.: 5)

Proceso de Entrenamiento

1. Configure la arquitectura y los parámetros de entrenamiento.
2. Haga clic en "Train Neural Network".
3. Observe el progreso del entrenamiento:
 - La barra de progreso muestra la época actual.
 - El registro muestra pérdida de entrenamiento/validación por época.
4. Cuando CV Folds > 1, el entrenador realiza validación cruzada K-fold completa y reporta media $\pm$ desv. std. del CV score.
5. El entrenamiento se detiene automáticamente cuando:
 - Se alcanzan las épocas máximas, O.
 - Se activa early stopping (sin mejora).

Optimización de Redes Neuronales

La pestaña Neural Network ahora soporta optimización completa de hiperparámetros vía Optuna, similar a los regresores de scikit-learn.

Configuración de Optimización

- Number of Trials: Cuántas combinaciones de arquitectura probar (10-200).
- CV Folds (Optimization): CV K-fold usada durante cada ensayo (1-10, predet.: 5).

Rangos de Optimización Personalizados

Haga clic en "Edit Optimization Ranges" para personalizar el espacio de búsqueda de:

- Número de capas ocultas.
- Unidades por capa.
- Tasa de dropout.
- Funciones de activación.
- Activación de batch normalization.
- Learning rate.
- Batch size.
- Weight decay.

- Selección de optimizador.

Haga clic en "Reset Ranges to Default" para restaurar los valores de fábrica.

Proceso de Optimización

1. Configure los ajustes y rangos de optimización.
2. Haga clic en "Start Optimization".
3. El sistema explora combinaciones de arquitectura vía optimización Bayesiana.
4. Después de completar, haga clic en "Apply Best Parameters to Architecture" para aplicar los hiperparámetros óptimos a la interfaz automáticamente.
5. Luego haga clic en "Train Neural Network" para entrenar con los valores optimizados.

Guardar Redes Neuronales

Después del entrenamiento:

1. Haga clic en "Save Model".
2. Elija formato:
 - PyTorch Model (.pt): Formato simple.
 - Model Bundle: Incluye manifest.json, modelo y preprocesador (recomendado para la pestaña Predict).

 **Importante:** Guarde siempre como Model Bundle si planea usar el modelo en la pestaña Predict. El bundle incluye toda la información de preprocesamiento necesaria.

Pestaña Optimization (Optimización)

La pestaña Optimization utiliza optimización Bayesiana (Optuna) para encontrar los mejores hiperparámetros para sus modelos.

Selección de Modelo

Seleccione un solo modelo para optimizar del desplegable:

- Random Forest.
- Gradient Boosting.
- XGBoost.
- LightGBM.
- CatBoost.
- SVR.

Configuración de Optimización

- Number of Trials: Cuántas combinaciones de hiperparámetros probar (10-500).
- Timeout: Tiempo máximo de optimización en segundos (0 = sin límite).
- Enable Pruning: Detener ensayos sin promesa temprano (recomendado).
- CV Folds: Validación cruzada K-fold durante optimización (1-10, predet.: 5).

Rangos de Parámetros Personalizados

Haga clic en "Edit Parameter Ranges" para personalizar el espacio de búsqueda. Para cada parámetro, puede establecer Min Value, Max Value y Type (Integer o Float).

Parámetros Disponibles por Modelo

Modelo	Parámetros
Random Forest	n_estimators, max_depth, min_samples_split, min_samples_leaf.
Gradient Boosting	n_estimators, max_depth, learning_rate, subsample.
XGBoost	n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda.
LightGBM	n_estimators, max_depth, learning_rate, num_leaves, subsample, colsample_bytree, reg_alpha, reg_lambda.
CatBoost	iterations, depth, learning_rate, l2_leaf_reg.

Modelo	Parámetros
SVR	C, epsilon, gamma.

Haga clic en "Reset to Default" para restaurar los rangos originales.

Proceso de Optimización

1. Seleccione el modelo y configure los ajustes.
2. (Opcional) Edite los rangos de parámetros.
3. Haga clic en "Start Optimization".
4. Monitoree el progreso:
 - La barra de progreso muestra el ensayo actual.
 - El registro muestra resultados de ensayos en tiempo real.

Resultados

Después de la optimización:

- Best Parameters: Valores óptimos de hiperparámetros encontrados.
- Best Score: Mejor rendimiento alcanzado.
- Number of Trials: Total de ensayos completados.
- Optimization Time: Tiempo total transcurrido.
- Trial History Table: Historial completo de todos los ensayos.

Entrenar con Mejores Parámetros

Haga clic en "Train with Best Parameters" para entrenar un nuevo modelo usando los hiperparámetros optimizados del mejor ensayo.

- El modelo optimizado se registra automáticamente en la pestaña Results.
- Aparece como {ModelType}_Optimized con métricas de prueba completas y CV scores.

Guardar Modelos Optimizados

Haga clic en "Save Optimized Model":

- Elija formato: Model Bundle (recomendado) o Legacy Format.
- Seleccione carpeta de destino.
- El modelo se guarda y aparece en la pestaña Results.

 **Pro Tip:** Comience con 50 ensayos para exploración inicial. Aumente a 100-200 para modelos de producción.

Pestaña Results (Resultados)

La pestaña Results muestra todos los modelos entrenados, optimizados y por conjuntos en cuatro sub-pestañas dedicadas.

Resultados de Entrenamiento

Todos los modelos entrenados se muestran en una tabla con:

- Model Name: Identificador.
- Type: Modelo entrenado.
- RMSE: Error Cuadrático Medio.
- MAE: Error Absoluto Medio.
- R^2 : Coeficiente de determinación.
- CV Score: Media $\pm$ desv. std. del score de validación cruzada.

Resultados de Optimización

Los modelos optimizados muestran:

- Model Name: {ModelType}_Optimized.
- Best Score: Score del mejor ensayo de Optuna.
- CV Score: Media $\pm$ desv. std. de los CV scores de los pliegues del mejor ensayo.
- Number of Trials: Total de ensayos de optimización completados.
- Optimization Time: Tiempo total transcurrido.

Resultados de Redes Neuronales

Los modelos de redes neuronales muestran:

- Model Name: Neural Network o NN_Optimized.
- Epochs: Iteraciones de entrenamiento completadas.
- Final Loss: Pérdida de entrenamiento y validación.
- CV Score: Media $\pm$ desv. std. del CV score (cuando CV folds > 1).

Resultados de Conjuntos

Los modelos por conjuntos muestran:

- Ensemble Name: Identificador auto-generado.
- Ensemble Type: Promedio ponderado o Stacking.
- Member Models: Lista de modelos incluidos.
- Member Weights: Peso asignado a cada miembro.
- Test Metrics: RMSE, MAE, R^2 en conjunto de prueba.

- CV Score: Media $\pm$ desv. std. del CV score.

Acciones

Para cada modelo, puede:

- Details: Ver información detallada del modelo.
- Delete: Eliminar el modelo de la lista.
- Export: Guardar como model bundle o formato legacy.

Detalles del Modelo

Haciendo clic en "Details" se muestra:

- Tipo de modelo y fuente.
- Tiempo de entrenamiento/optimización.
- Todas las métricas de rendimiento.
- Mejores parámetros (para modelos optimizados).
- Importancia de características (si está disponible).
- Arquitectura de red neuronal (para modelos NN).
- Pesos de miembros (para modelos por conjuntos).

Curvas de Aprendizaje

Seleccione un modelo y haga clic en "Generate Learning Curves" para visualizar pérdida de entrenamiento vs validación a lo largo de las épocas. Esto ayuda a diagnosticar sobreajuste/subajuste.

Exportar Modelos

1. Seleccione el modelo del desplegable.
2. Haga clic en "Export Model Bundle".
3. Elija carpeta de destino.
4. El bundle contiene:
 - manifest.json: Metadatos del modelo.
 - pipeline.joblib o model.pt: Modelo entrenado.
 - preprocessor.joblib: Pipeline de preprocesamiento (para NN).

Pestaña Ensemble (Conjunto)

La pestaña Ensemble le permite combinar múltiples modelos para mejorar las predicciones, ahora con optimización de pesos y soporte de stacking.

Seleccionar Modelos

1. Haga clic en "Refresh Model List" para cargar modelos disponibles.
2. Seleccione múltiples modelos de la lista (Ctrl+Clic para múltiples).
3. Fuentes disponibles:
 - Modelos entrenados de la pestaña Training.
 - Modelos optimizados de la pestaña Optimization.
 - Modelos de redes neuronales de la pestaña Neural Network.

Configuración del Conjunto

Tipo de Conjunto

- Weighted Average: Promedio ponderado igual o optimizado de las predicciones de los miembros.
- Stacking: Meta-aprendizaje de regresión Ridge entrenado sobre las predicciones de los miembros.

CV Folds

Establezca los pliegues de validación cruzada K-fold para la evaluación del conjunto (1-10, predet.: 5). Cuando > 1, el conjunto se evalúa vía CV K-fold completa.

Número de Modelos

Muestra cuántos modelos están seleccionados.

Crear Conjunto

1. Seleccione 2 o más modelos.
2. Elija tipo de conjunto.
3. Establezca los CV folds.
4. Haga clic en "Create Ensemble".
5. Espere a que la evaluación se complete.

Optimización de Pesos

Haga clic en "Optimize Weights" para usar optimización Bayesiana (Optuna) y encontrar los pesos óptimos de los miembros:

- Número configurable de ensayos (10-200).
- CV Folds (Optimization): CV K-fold durante la búsqueda de pesos (1-10, predet.: 5).
- Reporta peso optimizado por cada modelo miembro.

Después de la optimización, haga clic en "Apply Optimized Weights" para actualizar la configuración del conjunto.

Resultados del Conjunto

Después de la creación, verá:

- Ensemble Name: Identificador auto-generado.
- Ensemble Type: Promedio ponderado o Stacking.
- Test Metrics: RMSE, MAE, R^2 en conjunto de prueba.
- Training Metrics: RMSE, MAE, R^2 en conjunto de entrenamiento.
- CV Score: Media $\pm$ desv. std. del CV score.

Guardar Conjuntos

Haga clic en "Save Ensemble Model":

- Elija formato (Bundle o Legacy).
- Seleccione carpeta de destino.
- El conjunto aparece en la pestaña Results y puede usarse en Explainability.

 **Pro Tip:** Los conjuntos funcionan mejor al combinar modelos con diferentes fortalezas. Intente combinar un modelo basado en árboles (Random Forest) con uno de gradient boosting (XGBoost) y una red neuronal.

Pestaña Explainability (Explicabilidad)

La pestaña Explainability proporciona herramientas de interpretación de modelos incluyendo valores SHAP, importancia por permutación y gráficas de dependencia parcial.

Selección de Modelo

1. Haga clic en "Refresh Model List" para cargar modelos disponibles.
2. Seleccione un modelo del desplegable.
3. Modelos disponibles: Trained, Optimized, Neural Network, Ensemble.

 **Nota:** Para modelos por conjuntos, se mostrará un mensaje informativo ya que la explicabilidad de conjuntos no está soportada. Para modelos NN optimizados, el sistema le guiará a entrenar primero.

Opciones de Análisis

Seleccione qué análisis ejecutar:

- Compute SHAP Values: Contribuciones de características usando SHAP.
- Compute Permutation Importance: Importancia de características vía permutación.
- Compute Partial Dependence Plots: Visualización de efectos de características.
- Analyze Domain Applicability: Análisis de cobertura de datos.

Número de Características

Establezca cuántas características principales mostrar (1-100, predeterminado: 10).

Ejecutar Análisis

1. Seleccione modelo y opciones.
2. Haga clic en "Run Explainability Analysis".
3. Monitoree el progreso en el área de registro.
4. Los resultados aparecen en pestañas inferiores.

Pestañas de Resultados

Feature Importance

Tabla mostrando:

- Feature: Nombre de la característica.
- Model Importance: Importancia integrada (si está disponible).

- Permutation: Puntuación de importancia por permutación.
- SHAP: Valor SHAP absoluto medio.
- Average Rank: Ranking combinado entre métodos.

 **Nota:** Para Redes Neuronales, Model Importance muestra "N/A" ya que no tienen importancia integrada.

SHAP Values

Resumen del análisis SHAP:

- Importancia global de características (top N características).
- Valor SHAP absoluto medio por característica.

 **Nota:** Los valores SHAP se calculan usando KernelExplainer para compatibilidad universal entre todos los tipos de modelos.

Partial Dependence

Lista de características analizadas con gráficas de dependencia parcial.

 **Nota:** Las gráficas de Dependencia Parcial no están disponibles para Redes Neuronales debido a limitaciones de sklearn.

Domain Applicability

Análisis del dominio de aplicabilidad del modelo:

- Training Samples: Número de muestras de entrenamiento.
- Original Features: Número de características de entrada.
- PCA Components: Número de componentes PCA usados.
- Explained Variance: Varianza capturada por PCA.
- Thresholds: Umbrales de Leverage, Mahalanobis, distancia k-NN.

Prediction Explanation

Explicar predicciones individuales:

- Ingrese el índice de instancia (número de fila).
- Haga clic en "Explain Prediction".
- Ver: Valor predicho, contribuciones SHAP (características principales), Principales contribuyentes positivos/negativos.

 **Contexto para la ciencia de materiales** Entender qué características impulsan las predicciones es crucial en ciencia de materiales. Por ejemplo, saber que las diferencias de electronegatividad influyen fuertemente en las predicciones de band gap puede guiar el diseño de materiales.

Pestaña Predict (Predicción)

La pestaña Predict le permite hacer predicciones en nuevos datos usando modelos guardados.

⚠ Importante: La pestaña Predict es un diferenciador clave de AutoAIM Studio. Habilita el modo de predicción independiente para desplegar modelos entrenados en nuevos materiales sin reentrenar.

Cargar un Modelo

1. Haga clic en "Load Model Bundle".
2. Seleccione la carpeta que contiene:
 - manifest.json (requerido).
 - pipeline.joblib o model.pt (requerido).
 - preprocessor.joblib (si aplica).

La información del modelo se mostrará, incluyendo:

- Tipo de modelo y algoritmo.
- Nombres de características esperadas.
- Nombre de columna objetivo.
- Métricas del modelo (si están disponibles).

Cargar Datos de Predicción

1. Haga clic en "Load Prediction Data".
2. Seleccione su archivo CSV o Excel.
3. Aparecerá la vista previa de datos.

Validación de Características

El sistema verifica si todas las características requeridas están presentes:

- Verde: Todas las características presentes.
- Amarillo: Las características faltantes pueden auto-generarse.
- Rojo: Las características faltantes no pueden generarse.

Auto-Generar Características

Si sus datos tienen una columna de fórmula (por ejemplo, "composition", "formula"):

- Marque "Auto-generate composition features from formula column if missing."
- El sistema generará 106 descriptores de composición automáticamente.

Hacer Predicciones

1. Asegúrese de que todas las características requeridas estén presentes (estado verde).
2. Haga clic en "Make Predictions".

Exportar Predicciones

1. Haga clic en "Export Predictions".
 - Elija ubicación de guardado.
 - Las predicciones se guardan como CSV con todas las columnas originales más nueva columna de predicción.

 **Pro Tip:** Use la pestaña Predict para examinar grandes bases de datos de materiales. Entrene con un conjunto pequeño bien caracterizado, luego prediga propiedades para miles de materiales candidatos.

Solución de Problemas

Problemas Comunes

No se pueden generar características faltantes automáticamente

Causa: Faltan características de composición y no se detectó columna de fórmula.

Solución:

- Asegúrese de que sus datos de predicción tengan una columna con fórmulas químicas.
- Marque la casilla "Auto-generate composition features".
- El nombre de la columna debe contener "formula", "composition" o "structure".

El modelo seleccionado no tiene método predict

Causa: El objeto de modelo está corrupto o no se cargó correctamente.

Solución:

- Reentrene el modelo.
- Verifique si el modelo se guardó correctamente.
- Para Redes Neuronales, asegúrese de que el modelo se construyó antes de entrenar.

Modelo 'X' no encontrado en ninguna fuente

Causa: El modelo fue eliminado o no se almacenó correctamente.

Solución:

- Reentrene el modelo.
- Guarde el modelo nuevamente después del entrenamiento.

Valores SHAP no disponibles para este modelo

Causa: El cálculo de SHAP falló (usualmente para Redes Neuronales).

Solución:

- Asegúrese de que el modelo tenga un método predict funcionando.
- Intente con una muestra más pequeña del conjunto de datos.
- Revise la consola para mensajes de error detallados.

CV scores negativos o incorrectos en la pestaña Results

Causa: Versiones anteriores promediaban los CV scores entre todos los ensayos, produciendo valores engañosos.

Solución: Esto está corregido en v1.1.0. El optimizador ahora almacena los CV fold scores del mejor ensayo únicamente.

Consejos de Rendimiento

Acelerar Entrenamiento

- Reducir pliegues CV: Use 3 en lugar de 5.
- Usar GPU: Habilitar aceleración GPU para Redes Neuronales.
- Reducir ensayos: Use menos ensayos de optimización (20-30 en lugar de 50+).
- Muestrear datos: Entrene con un subconjunto para exploración inicial.

Mejorar Precisión

- Generar características de composición: Use los 106 descriptores.
- Optimizar hiperparámetros: Ejecute optimización con más ensayos.
- Crear conjuntos: Combine múltiples modelos con optimización de pesos.
- Probar diferentes algoritmos: No todos los algoritmos funcionan igual para todos los conjuntos de datos.

Reducir Uso de Memoria

- Deshabilitar características de composición: Si no son necesarias.
- Reducir batch size: Para Redes Neuronales.
- Usar menos ensayos de optimización: Cada ensayo mantiene resultados en memoria.

Obtener Ayuda

Si encuentra problemas no cubiertos aquí:

- Revise la salida de registro en cada pestaña.
- Revise la consola/terminal para mensajes de error detallados.
- Asegúrese de que sus datos estén correctamente formateados (CSV/Excel).
- Verifique que todas las columnas requeridas estén presentes.

Referencia de Características

Características de Composición (106 Descriptores)

El generador de características de composición personalizado calcula las siguientes estadísticas para cada fórmula química:

Propiedades Atómicas

- Número atómico (media, std, min, max, rango, mediana, percentiles).
- Masa atómica (media, std, min, max, rango, mediana, percentiles).
- Radio covalente (media, std, min, max, rango, mediana, percentiles).
- Radio de Van der Waals (media, std, min, max, rango, mediana, percentiles).

Propiedades Electrónicas

- Electronegatividad (media, std, min, max, rango, mediana, percentiles).
- Energía de ionización (media, std, min, max, rango, mediana, percentiles).
- Afinidad electrónica (media, std, min, max, rango, mediana, percentiles).

Propiedades Físicas

- Densidad (media, std, min, max, rango, mediana, percentiles).
- Punto de ebullición (media, std, min, max, rango, mediana, percentiles).
- Punto de fusión (media, std, min, max, rango, mediana, percentiles).

Propiedades de la Tabla Periódica

- Número de grupo (media, std, min, max, rango, mediana, percentiles).
- Número de periodo (media, std, min, max, rango, mediana, percentiles).

Características Adicionales

- Número de elementos únicos.
- Número total de átomos.
- Fracciones de elementos.

Estas características se calculan a partir de propiedades elementales y proporcionan una representación comprehensiva de la composición de materiales para modelos de machine learning.

 **Materials Science Context:** Los 106 descriptores capturan distribuciones estadísticas de propiedades elementales dentro de un compuesto. Por ejemplo, Fe_2O_3 generaría estadísticas basadas en las propiedades de Fe y O, ponderadas por sus razones estequiométricas.

Apéndice: Algoritmos de Modelos

Este apéndice proporciona información detallada sobre cada algoritmo disponible en AutoAIM Studio.

Random Forest

- Tipo: Conjunto de árboles de decisión.
- Fortalezas: Maneja relaciones no lineales, robusto a valores atípicos.
- Mejor para: Regresión de propósito general, importancia de características.

Gradient Boosting

- Tipo: Conjunto secuencial.
- Fortalezas: Alta precisión, maneja patrones complejos.
- Mejor para: Precisión competitiva, conjuntos de tamaño medio.

XGBoost

- Tipo: Gradient boosting optimizado.
- Fortalezas: Rápido, regularizado, maneja valores faltantes.
- Mejor para: Competiciones de datos tabulares, sistemas de producción.

LightGBM

- Tipo: Gradient boosting basado en histogramas.
- Fortalezas: Muy rápido, eficiente en memoria.
- Mejor para: Conjuntos grandes, aplicaciones críticas de velocidad.

CatBoost

- Tipo: Gradient boosting con ordered boosting.
- Fortalezas: Excelente manejo categórico, reducción de sobreajuste.
- Mejor para: Conjuntos con muchas características categóricas.

SVR (Support Vector Regression)

- Tipo: Método basado en kernels.
- Fortalezas: Efectivo en altas dimensiones, eficiente en memoria.
- Mejor para: Conjuntos pequeños a medianos, relaciones no lineales.

Ridge Regression

- Tipo: Regresión lineal con regularización L2.

- Fortalezas: Simple, rápido, previene sobreajuste.
- Mejor para: Modelo de línea base, relaciones lineales.

Neural Networks

- Tipo: Deep learning con arquitectura personalizable.
- Fortalezas: Aprende patrones no lineales complejos.
- Mejor para: Conjuntos grandes, interacciones complejas de características.

Tarjeta de Referencia Rápida

Atajos de Teclado

Acción	Atajo/Ubicación
Cargar Datos	Pestaña Data > botón Load Data.
Preparar Datos	Pestaña Data > botón Prepare Data.
Entrenar Modelos	Pestaña Training > Train Selected Models.
Guardar Modelo	Pestaña Results > Export Model Bundle.
Hacer Predicciones	Pestaña Predict > Make Predictions.

Guía de Problema-Solución

Si tiene este problema...	Haga esto...
El entrenamiento es muy lento.	Reduzca pliegues CV o use GPU.
Baja precisión del modelo.	Genere características de composición, intente optimización.
Sin memoria.	Reduzca batch size, deshabilite características de composición.
Características faltantes en Predict.	Habilite auto-generar características de composición.
El modelo no carga.	Verifique que manifest.json exista en la carpeta del bundle.

Cita y Licencia

Cómo Citar

Si usa AutoAIM Studio en su investigación, por favor cite:

```
@software{autoaim_studio, title = {AutoAIM Studio: Automated Machine Learning for  
Materials Science}, version = {1.1.0}, year = {2026}, url =  
{https://github.com/cesargabrielvera1-ux/AutoAIM-Studio.git}, doi =  
{10.5281/zenodo.19478356} }
```

El software también está disponible en Zenodo con DOI: [10.5281/zenodo.19478356](https://doi.org/10.5281/zenodo.19478356).

Licencia

AutoAIM Studio se distribuye bajo la Licencia MIT. Es libre de usar, modificar y distribuir este software para fines académicos y comerciales.

Agradecimientos

AutoAIM Studio se construye sobre las siguientes bibliotecas de código abierto:

- scikit-learn: Algoritmos de machine learning.
- XGBoost: Framework de gradient boosting.
- LightGBM: Gradient boosting rápido.
- CatBoost: Categorical boosting.
- PyTorch: Framework de redes neuronales.
- Optuna: Optimización de hiperparámetros.
- SHAP: Interpretabilidad de modelos.
- pymatgen: Análisis de materiales.

AutoAIM Studio

Machine Learning Automatizado para Ciencia de Materiales

veradelagarza@quimica.unam.mx

© 2026 AutoAIM Studio. Todos los derechos reservados.

